

Estadístico Descriptivo

Permite

- Conocer reglas y métodos usados en el tratamiento de datos
- Evaluar y cuantificar la importancia de los resultados estadísticos
- Entender fenómenos de la realidad (sociales, biológicos...)
- Dar visión clara de la información proveniente de distintas fuentes

Estadística

↳ Marco de Información Cuantificable

- Descripción de datos
- Inferencia = concluir

↳ Estudia fenómenos aleatorios y su comportamiento (variabilidad)

↳ Funciones

- Resumir = Graficamente o Numericamente
- Simplificar
- Comparar
- Relacionar
- Proyectar

↳ Tareas

- ① • Delimitar estudio
- Establecer Unidades
- Definir Variables
- ② Observar
 - Censo
 - Muestreo
 - Diseño experimental
- ③ Recolección y registro de datos
- ④ Depurar información
- ⑤ Resumir = Gráf. Numérico
- ⑥ Interpretar

TOPICOS

- Diseño experimental
- Estadística Descriptiva (tareas)
- Inferencia
- Estadística no paramétrica (modelos sin supuestos previos)
- Elementos de regresión (variables respuesta y explicativa)

TIPOS DE VARIABLES

↳ Características que varían

- Estatura
- Presión Sanguínea

- ↳
- ① **Continuas** = Mediciones, Estatura de un grupo
 - ② **Discretas** = Conteos, # autos en un semáforo, horas
 - ③ **Categoricas** = Clasificación, Sexo, estrato

NIVELES DE MEDICION

- ① Nominal = representan categorías, Estado civil = C, S, M, no cumple 1, 2, 3
No medidas básicas de resumen
- ② Ordinal = representan jerarquías, Queraduras = 1, 2, 3 se cumple 1, 2, 3
No medidas básicas de resumen
- ③ Intervalo = cuantitativas
- ④ Razón = Cuantitativa con escala, Estofanía, Presión sanguínea

DESCRIPCION DE DATOS

4) Distribuciones de frecuencia

- Tabla de frecuencia

- Encuentre Mínimo y Máximo de los valores registrados

- Defina Intervales de clase

- Sturges

$$K = 1 + 3,33 \log_{10}(n)$$

$K = \text{Número de Clases}$

- Velleman n Pequeño

$$K = 2 \sqrt{n}$$

$n = \text{Número de datos}$

- Dixon y Kronmal n Grande

$$K = 10 \cdot \log_{10}(n)$$

Notas:

- * Entre 5 y 25 clases es lo adecuado

- * Pocas clases \Rightarrow Gran pérdida de información

- * Pocos datos \Rightarrow No se evidencian

Muchas clases Comportamientos

- * Dentro de las clases es importante

Organizar (Menor a Mayor)

- Cuenta las observaciones por cada subintervalo
(Frecuencia de clase)

- Calcule la frecuencia relativa

$$FR = \frac{\text{Frecuencia de clase}}{\text{total de observaciones}}$$

$$\# \text{ total de observaciones}$$

Ejemplo: tabla dada:

Masa	Estatura	Edad	Género	Estrato	Gasto	Longitud	Tipo	Horas o estrato
Kg	cm	años	H, M	1 a 5	\$	Alumnos	colegio	pu
Tiempo en llegar	Longitud pres prom	Longitud metros prom						horas
Min	cm	cm						

- Tabla de frecuencia para género

	Frecuencia	Porcentaje
HombrE	46	68,66
Mujer	21	31,34

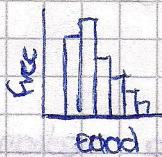
67 DATOS

- En la Edad el gráfico de barras no es dicante (Se hizo intervalos de clase) (8 clases)

Categoría	Frecuencia	Frecuencia Relativa
≥ 6300	20	0,299
(6300, 6900)	20	0,358
(6900, 7500)	11	0,164
(7500, 8100)	9	0,060
(8100, 8700)	3	0,045
(8700, 9300)	2	0,030
(9300, 10000)	2	0,030
> 10000	1	0,015

se aplica la fórmula

- Nuevo Gráfico frecuencia Vs edad



- Para la estatura definieron clases

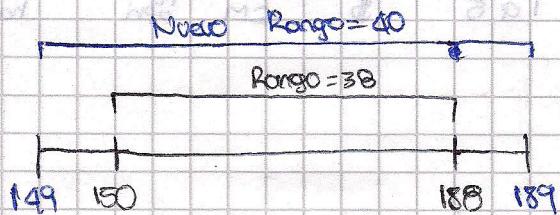
$$\text{Storges} \rightarrow K = 1 + 3,33 \log_{10}(67) = 7,08 \approx [8]$$

* El valor máximo es ~~188~~ 188 cm y el mínimo 190
el rango es 1900 a 38

La Amplitud de cada intervalo está dado por

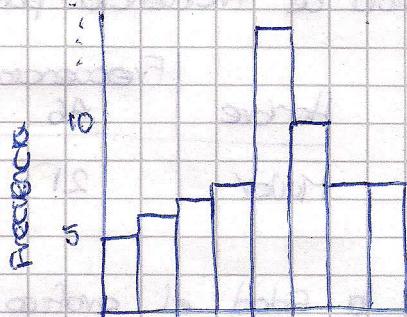
$$A = \frac{\text{Rango}}{K} = \frac{38}{8} = 4,75 \approx [5]$$

Como hay un excedente de dos se repartirán equitativamente



La tabla quedaría así:

Intervalo	Frecuencia	FR	Medio
149, 159	5	0,045	151,5
159, 159	6	0,090	156,5
159, 169	7	0,104	161,5
169, 169	8	0,119	166,5
169, 179	17	0,254	173,5
179, 179	10	0,199	176,5
179, 189	7	0,104	181,5
189, 189	7	0,104	186,5



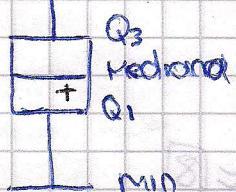
NOTA: Los tablas de frecuencia deben contar con:

- Uniformidad: Clases de igual amplitud o variable que dependen del tipo de datos
- Chicidad: Clases no traspasadas
- Completez: Cada dato pertenece a una y sólo una clase

Box-Plot (Cañas y Bigotes)

Usa para describir las características importantes de un conjunto de datos

1 Max



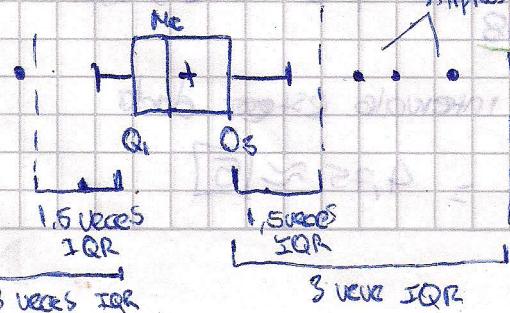
Q = Cuartil

→ 50% de los datos
nos centrales

Nota: la mediana y la moda, no siempre están en el mismo lugar

+ Media muestral

2



3 veces IQR

3 veces IQR

- Medidas de localización y de tendencia central
 ■ Medidas de dispersión (variabilidad)

DD MM AA

ANÁLISIS DESCRIPTIVO DE UN CONJUNTO DE DATOS

- Datos agrupados = Crear clases // hacer frecuencia
- Datos sin agrupar = Manipulación de la información como se formó

Datos Agrupados

Muestra

$$\bar{x} = \frac{\sum_{i=1}^n \text{Marca de clase} \cdot \text{Frecuencia de clase}}{\text{Total de frecuencia}}$$

Ejemplo

$$\bar{x} = 170,38$$

Moda

- ↳ Marca de clase con la mayor frecuencia

Ejemplo

$$\text{Moda} = 171,5$$

Percentiles (P_p)

- ↳ Valores abajo y arriba de los cuales se encuentra una cierta proporción de datos del conjunto

$$P_{50} \Rightarrow p = 0,5$$

$$P_{25} \Rightarrow p = 0,25$$

$$P_p = L + \frac{(P - q) \times h}{f}$$

P: Percentil

F: FR de la clase que contiene el percentil

L: Límite inferior de la clase que contiene el percentil

p: Percentil a calcular ($P_{50} \Rightarrow p = 0,5$)

Datos Sin agrupar

Muestra

Sensible a valores extremos

\bar{x} : Promedio

$$= \frac{\sum \text{de datos}}{\# \text{ de datos}}$$

Moda

- ↳ Dato con mayor frecuencia (Dato que más se repite)

Ordenar datos

Percentiles

- ↳ Homólogo de los cuantiles (%)

AF FR Acumulada del intervalo anterior al del percentil

h = longitud de clase del Percentil

Ejemplo P₉₀

$$P_{90} = 169 + \frac{(0,5 - 0,88) \times 5}{0,254}$$

$$P_{90} = 171,2$$

Mediana

↳ Es igual al P₅₀

Variancia

$$S_a^2 = \sum_{i=1}^k (m_i - \bar{x}_a)^2 \times f_i$$

Rango intercuartil

↳ diferencia entre el Percentil 75 y el 25
(Datos mas centrales)

$$Q_{\text{RANGE}} = Q_3 - Q_1 = P_{75} - P_{25}$$

Ejemplo

$$S_a^2 = 101,4$$

$$S_d = 10,07$$

$$P_{25} = 163,1$$

$$P_{75} = 177,6$$

$$Q_{\text{RANGE}} = 14,5$$

Mediana

↳ Dato central

Impar = $\frac{1}{2}$
Datos Par = el prom de los dos ordenados centrales

$$\tilde{x} = \frac{x_{(n/2)} + x_{((n/2)+1)}}{2} \quad \text{Par}$$

$$\tilde{x} = \frac{x_{(n/2)}}{2} \quad \text{Impar}$$

$$\bullet 5 \quad 7 \quad 9$$

$$\begin{array}{c} \bullet 5 \\ 3 \\ 8 \\ 5 \\ 3 \\ 7 \\ 8 \end{array}$$

$$\downarrow \frac{5+7}{2} = 6$$

Variancia

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

A mayor Variancia mayor dispersion

- Desviación Estándar

↳ Raíz de la Variancia

Rango intercuartil

$$Q_{\text{RANGE}} = Q_3 - Q_1 = P_{75} - P_{25}$$

Coefficiente de Variación

$$C.V. = \frac{S_d}{\bar{x}} = \frac{\text{Desviación estandar}}{\text{media}}$$

A mayor valor mayor dispersion

1. Importar Datos

Datos %>% Importar datos %>% Desde archivo Excel
Desde archivo de texto

2. Resumen y tipo de datos

Summary (df)
Str (df)

3. Modificar Datos

3.1 Conversión de factores

Datos %>% Modificar Variable del %>% Recodificador variables
conjunto de datos
activos

%>% Escoger Variables

1 == "verdad"
2 == "falso"

Para Proporciones

3.2 Nuevas Variables

Datos %>% Modificar Variable del %>% Calcular nuevo variable
conjunto de datos
activos

- Factor (Ifelse (Condicion, "Verdadero", "falso")) Prop
- Formula : Variable 1 * Variable 2 =

3.3 Eliminar factores no necesarios

Datos %>% Modificar variable del %>% Descartar niveles sin
conjunto de datos
activo

Todos los factores

4. Agrupar Datos (filtrar)

Datos %>% Conjunto de datos activo %>% Filtrar el conjunto
de datos activos

Incluir todos los variables

Expresión de
selección

- Para un factor : df == "factor1"
- Para 2 o mas factores : df == "factor1" | df == "factor2"

5. Estadísticos de Interés (Pruebas No Normales o σ conocidas)

Estadísticos %>% Resúmenes %>% Resúmenes numéricos %>%

Resumir por %>% Seleccionar %>% Estadísticos
grupo Variables de interés

Media

Desviación típica

(96) unívoca

(96) NIV

6. Juego de hipótesis para medias

H_0 = Complemento

Cola derecha

H_a = Lo que queremos : Cola izquierda

Bilateral

6.1 Test de Normalidad

- Prueba de hipótesis

Estadísticos %>% Resúmenes %>% Test de Normalidad

{ P-Value > α } %>% Test
{ Son normales } por grupos

- Q-Q plot

Graficos %>% Graficos de comparación de cuantiles

- Histograma

Graficos %>% Histograma

6.2 Homocedasticidad (Razón de Varianzas)

Cuidado: "factor en orden alfabetico"

Teniendo los dos factores agrupados

Estadísticos %>% Varianzas %>% Test F para dos %>%

Varianzas Bilateral

Convertir var # en factor

{ P-Value > α }

{ Son iguales $\sigma_1^2 = \sigma_2^2$ }

6.3 Ph (T-Student) Para 1 Medio

Estadísticos %>% Medias %>% Test t para una muestra

- Ingresar H_0

$$M_U = *$$

- Revisar α
- Analizar P-Value
- Concluir

6.4 Ph (T-Student) para dos medias

Estadísticos %>% Medios %>% Test t para muestras %>% Selección independientes Variable

Revisar factores
Voltear H_0 en
(caso de estar
truncados)

- Seleccionar H_0
- Revisar α
- Varianzas iguales

SI

ONO

*
Para mayor diferencia
selección variable

- Verificación Ph (gráficamente)

Graficos %>% Graficos de las medias

- ② Intervalos de confianza

6.5 Ph para una proporción

Estadísticos %>% Proporciones %>% Test de proporciones %>% para una muestra

$$H_0 = P_0$$

(Si los factores están truncados)

$$H_0 = 1 - P_0$$

6.6. Ph (Multinomial) (Chi-Cuadrado)

H_0 = Todos los probabilidades son iguales a las propuestas

H_a = Al menos una de las probabilidades es diferente a la propuesta

Estadísticos > Resúmenes > Distribución de frecuencias

- Ingresar valores

- Test Chi-Cuadrado de bondad de ajuste

- No hay evidencia en los datos con una significancia $\alpha = 0.05$.

$\beta_0 = 100$
 $\beta_1 = -8$
 $\beta_2 = 20$

Entonces se obtiene $\hat{Y} = 100 - 8P_1 + 20P_2$

variables de interés con el test de los intervalos de confianza
 Sección 10.3

β_0	β_1	β_2
100	-8	20
100	-8	20
100	-8	20
100	-8	20

(estimación) \hat{Y} variable

variable de interés \hat{Y}

variable de interés \hat{Y}

variable de interés \hat{Y}

variables de interés \hat{Y}
 Sección 10.3

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 P_1 + \hat{\beta}_2 P_2$$

estimación variable \hat{Y}

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 P_1 + \hat{\beta}_2 P_2$$

(estimación) \hat{Y} (estimación)

esta estimación es de $\hat{\beta}_0 + \hat{\beta}_1 P_1 + \hat{\beta}_2 P_2$

probabilidad es de 0.9999999999999999

probabilidad es de 0.9999999999999999

se obtiene la estimación \hat{Y} para $P_1 = 1$ y $P_2 = 0$